

杨宇辰

电话: (+86)13910442504 微信: NPhothard 出生年月: 2000 年 3 月 邮箱: yuchenyang@smail.nju.edu.cn  GitHub

教育背景

 南京大学, 电子科学与工程学院, 信息与通信工程, 博士

2022.09 – 2027.06

 华中科技大学, 物理学院, 物理学, 学士

2018.09 – 2022.06

成绩排名前 5% (6/166), 曾获国家奖学金、本科特优生

研究方向

我博士期间的研究处于算法理论与系统级优化的交叉领域, 围绕边缘与端侧计算环境, 设计、分析并实现系统调度与优化算法, 以支持在线通用计算与 AI 负载。目前的研究兴趣集中在端侧大语言模型系统, 重点关注 MoE 模型与多模态大模型在端侧设备上的系统级推理加速。

科研经历

- 基于无损压缩与缓存调度联合设计的端侧 MoE 大模型推理加速系统**  ICML 2026
Project Lead & First Author
S/T: MoE 架构大模型因巨大的内存开销而难以在端侧设备上高效运行。然而, 目前的推理优化手段 (如量化、剪枝等) 虽能减小模型体积, 但会带来性能退化或潜在安全风险; 基于卸载或 CPU-GPU 混合推理的系统则与移动端硬件架构不匹配, 难以保证低延迟。本研究目标是设计一套在端侧快速、高效、且完全保留模型能力的 MoE 推理系统。
A: 1) 模型参数的无损压缩: 对 BF16 权重进行比特级分解, 提取低熵指数位并实施分块压缩与异步加载, 将 I/O 总量降低 30%, 并将参数加载过程转化为 CPU 多核可加速的异构并行计算工作流, 大幅提升系统并行度与推理效率。
2) 缓存调度联合设计: 提出压缩态抽象, 实现精细内存控制与缓存池划分; 将专家张量获取抽象为 DAG 调度问题, 设计 Pipeline 执行最优调度; 利用 Memory Coalescing 技术开发 CUDA Kernel, 实现张量比特恢复的高效 GPU 执行。
R: 在 NVIDIA Jetson AGX Orin 平台上, 将 MoE 模型推理的首字延迟降低 86%, 字间延迟降低 73%; 整体推理时延降低 72.77%; 批处理任务上提升 6.76 倍在系统吞吐量。
- 时延约束下边缘网络中的广义并行计算任务在线调度算法**  IEEE Transactions on Communications
Project Lead & First Author
S/T: 在资源受限的分布式边缘网络中, 由于系统同时受到计算请求的在线不确定性、计算-通信耦合以及异构计算并行度的影响, 导致 SLO 达成率难以保证。本研究以最大化满足时延约束任务的累计收益为优化目标, 建立统一的在线调度理论。
A: 1) 在线任务-节点匹配: 基于任务资源需求特征与节点负载状态, 设计基于特殊结构的阈值函数来指导任务的信道分配与节点指派, 在局部信息下实现负载均衡的在线决策。
2) SLO 感知的动态计算资源分配: 通过约束降维技术将计算与通信的耦合问题进行分解, 得到计算资源分配的结构化子问题; 结合任务剩余处理时间与各任务的异构并行加速曲线, 设计高效资源分配算法, 实现计算资源的自适应伸缩。
R: 在数学上形式化给出算法的最坏情况竞争比界, 并通过仿真验证其在 SLO 达成率与系统累计收益上的显著提升。
- 面向边缘网络的在线 Serverless 函数一体化编排框架** IEEE Transactions on Computers (Under Review)
Project Lead & First Author
S/T: Serverless 计算范式为资源受限的边缘网络提供了高资源利用率与弹性伸缩能力。然而, 函数冷启动开销、执行时间的强随机性、不可预测的到达模式, 以及边缘网络带宽受限与复杂拓扑的强耦合特性, 导致时延关键型服务的 SLO 难以保障。本研究针对边缘网络的 Serverless 函数服务, 提出端到端的在线一体化编排框架并提供相应的理论分析。
A: 1) 算网联合调度: 针对大规模数据交互与随机函数执行时间场景, 基于在线原始-对偶理论设计服务级路由与计算的联合调度算法; 在随机函数执行时间的模型下设计策略动态调整函数调度序列, 保证 SLO 的高概率满足。
2) 动态容器部署与缓存管理: 基于排队理论构建容器服务模型, 设计网络拓扑与并发度感知的动态容器缓存与部署算法, 在容器冷启动与热调用排队之间的实现折衷。
R: 在理论上构造对抗性实例证明优化问题的困难性结论; 在静态实例上证明算法的竞争比; 基于 Microsoft Azure 函数调用数据集的进行系统仿真实验, 验证了所提框架在 SLO 满足率的优势。

专业技能

编程语言: Python, C/C++, CUDA, MATLAB

软件与工具: Nsight Systems/Compute, Pybind11

硬件开发环境: NVIDIA Jetson Series (AGX Orin, Xavier, TX2)

荣誉奖项

- 南京大学优秀研究生，南京大学 2023.09, 2024.09
- 南京大学英才奖学金（一等），南京大学 2023.10, 2024.10
- 国家奖学金，中华人民共和国教育部 2020.10
- 华中科技大学本科特优生，华中科技大学 2020.10
- 三好学生，华中科技大学 2020.10
- 全国大学生数学竞赛，全国一等奖（初赛），中国数学会 2019.09

在投&预印本

- ♦ IntFaaS: An Integrated Framework for Online Serverless Orchestration at the Network Edge 
Yuchen Yang and Shaowei Wang
IEEE Transactions on Computers, 2026. (Under Review)

已发表论文

- ♦ ZipMoE: Efficient On-Device MoE Serving via Lossless Compression and Cache-Affinity Scheduling 
Yuchen Yang*, Yaru Zhao*, Pu Yang, Shaowei Wang, and Zhi-Hua Zhou
In Proc. of the 43rd International Conference on Machine Learning (ICML'26), Seoul, South Korea, Jul. 2026.
- ♦ EdgeOPT: A Competitive Algorithm for Online Parallel Task Scheduling with Latency Guarantee in Mobile Edge Computing 
Yuchen Yang and Shaowei Wang
IEEE Transactions on Communications, vol. 72, no. 11, pp. 7077-7092, Nov. 2024.
- ♦ Online Scheduling and Splittable Routing for Serverless Functions at Network Edge 
Yuchen Yang and Shaowei Wang
In Proc. of the IEEE Global Communications Conference 2024 (GLOBECOM'24), Cape Town, South Africa, Dec. 2024.
- ♦ Lightning in the Dark: Scheduling Non-Clairvoyant Coflows at Wireless Edge 
Yuchen Yang and Shaowei Wang
In Proc. of the IEEE Wireless and Optical Communications Conference 2025 (WOCC'25), Macau, China, May 2025.
 M-Tel Best Paper Award
- ♦ Joint Source-Channel Coding for Wireless Image Transmission: A Neural Architecture Search Approach 
Yuchen Yang and Shaowei Wang
In Proc. of the IEEE International Conference on Communications 2023 (ICC'23), Rome, Italy, May-Jun. 2023.

横向项目

- 电梯群控制调度算法研究 | 苏州汇川控制技术有限公司合作项目 | 唯一学生技术负责人 2023.09 – 2024.02
- 算法设计：针对普通群控/目的层群控/混合群控场景进行效率瓶颈分析，推导理论模型、设计并实现调度算法。
 - 功能构建：设计并实现智能化调度辅助模块，基于在线学习方法进行交通流模式识别以及算法参数自适应调优。
 - 仿真平台：参与电梯效率评估仿真系统的 Debug 与开发。
 - 项目成果：针对各类高楼与控制场景，成功将平均候梯时间降低 10%-30%。

专利

- 面向边缘网络的服务器无感知计算函数编排方法、系统及设备
王少尉；杨宇辰，发明专利，CN119718545B，已授权
- 一种基于无损压缩的端侧大模型推理加速方法及设备
王少尉；杨宇辰，发明专利，已申请（申请号：202610493006.X）

学术服务

- ▶ 期刊审稿
 - IEEE Journal on Selected Areas in Communications
 - IEEE Internet of Things Journal
- ▶ 课程教学
 - 数字通信（离散优化与近似算法专题，南京大学研究生课，2024Fall）